

Fundamentos de Extracción de Características en el Dominio del Tiempo para Señales Biomédicas

Documento Teórico Suplementario

Ricardo Amiel Acuña Villogas
Josué Nehemías Velo Poma

Departamento de Ciencia de Datos, Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú

30 de junio de 2026

Resumen

Este anexo formaliza matemáticamente el marco de extracción de características en el dominio del tiempo empleado en la rama clásica del pipeline de clasificación de esquizofrenia sobre electroencefalografía (EEG). Se sistematizan: (i) las limitaciones matemáticas de operar sobre la serie cruda, (ii) las estadísticas descriptivas y momentos de orden superior, (iii) las métricas de dependencia temporal, (iv) los descriptores de cambios de estado y dinámica no lineal, y (v) los imperativos de preprocesamiento. Cada descriptor se acompaña de su definición formal y su interpretación clínica en el contexto del análisis cortical.

1. Limitaciones Matemáticas de los Datos Crudos

Sea una ventana de señal EEG univariada $\mathbf{X} = (X_1, X_2, \dots, X_N)$ muestreada a frecuencia f_s . En nuestro caso, $f_s = 250$ Hz y una ventana de 5 s implica $N = 1250$ muestras por canal. Operar directamente sobre $\mathbf{X}$ presenta dos obstáculos formales.

1.1. Maldición de la Dimensionalidad

Una serie de longitud N se interpreta como un punto en el espacio euclidiano $\mathbb{R}^N$:

$$\mathbf{X} \in \mathbb{R}^N, \quad N = 1250 \text{ (por canal)}. \quad (1)$$

Considerando el montaje fronto-temporal de 6 canales, la representación cruda concatenada vive en $\mathbb{R}^{6 \times 1250} = \mathbb{R}^{7500}$. A medida que la dimensión N crece, el volumen del espacio crece exponencialmente y las observaciones se tornan asintóticamente equidistantes: la razón entre la distancia máxima y mínima entre pares de puntos converge a la unidad,

$$\lim_{N \rightarrow \infty} \frac{\text{dist}_{\text{máx}} - \text{dist}_{\text{mín}}}{\text{dist}_{\text{mín}}} \rightarrow 0, \quad (2)$$

lo que degrada las métricas de distancia (k -NN, SVM, k -means) y exige una reducción a un vector de características $\phi(\mathbf{X}) \in \mathbb{R}^d$ con $d \ll N$.

1.2. Dependencia Temporal y Violación del Supuesto IID

La mayoría de los algoritmos de aprendizaje automático asumen que las características son *independientes e idénticamente distribuidas* (IID). En una serie temporal este supuesto se viola por construcción: las muestras adyacentes están correlacionadas. Formalmente, existe dependencia de segundo orden no nula para algún retardo $k \neq 0$:

$$\text{Cov}(X_t, X_{t-k}) = \mathbb{E}[(X_t - \mu)(X_{t-k} - \mu)] \neq 0. \quad (3)$$

La extracción de características resuelve ambos problemas simultáneamente: mapea $\mathbf{X} \in \mathbb{R}^N$ a un vector compacto e interpretable $\phi(\mathbf{X}) \in \mathbb{R}^d$ cuyas componentes resumen explícitamente la estructura temporal (tendencia, autocorrelación, dinámica), restaurando una representación tabular tratable por modelos estándar.

2. Estadísticas Descriptivas y Momentos de Orden Superior

Los descriptores de primer y segundo orden resumen la distribución marginal de las amplitudes; los de tercer y cuarto orden capturan su forma.

2.1. Tendencia central y dispersión

$$\text{Media: } \bar{X} = \frac{1}{N} \sum_{t=1}^N X_t, \quad (4)$$

$$\text{Varianza: } \sigma^2 = \frac{1}{N-1} \sum_{t=1}^N (X_t - \bar{X})^2, \quad \sigma = \sqrt{\sigma^2}. \quad (5)$$

En EEG, σ^2 es proporcional a la *potencia* de la señal en la ventana; constituyó el descriptor más discriminante del estudio (`F3__variance`).

2.2. Asimetría (Skewness)

Tercer momento estandarizado; mide la asimetría de la distribución de amplitudes:

$$S = \frac{1}{N} \sum_{t=1}^N \left(\frac{X_t - \bar{X}}{\sigma} \right)^3. \quad (6)$$

$S > 0$ indica cola derecha más larga; $S < 0$, cola izquierda; $S \approx 0$, simetría (caso gaussiano).

2.3. Curtosis (Kurtosis)

Cuarto momento estandarizado; cuantifica el peso de las colas y la agudeza del pico:

$$K = \frac{1}{N} \sum_{t=1}^N \left(\frac{X_t - \bar{X}}{\sigma} \right)^4. \quad (7)$$

Una distribución gaussiana posee $K = 3$ (exceso de curtosis $K - 3 = 0$).

Interpretación clínica: valores de curtosis $K \gg 3$ (distribución leptocúrtica) señalan colas pesadas no gaussianas, típicamente inducidas por artefactos transitorios (parpadeos, movimiento, saltos de electrodo). La curtosis funciona así como un detector implícito de ruido impulsivo.

3. Métricas de Dependencia Temporal

La dependencia temporal es la esencia de la serie. Su captura explícita es lo que distingue a un descriptor temporal de una mera estadística marginal.

3.1. Autocovarianza muestral

Mide la relación lineal entre la señal en t y su versión retardada k pasos:

$$\gamma_k = \frac{1}{N} \sum_{t=k+1}^N (X_t - \bar{X}) (X_{t-k} - \bar{X}). \quad (8)$$

Bajo estacionariedad, γ_k depende solo del retardo k .

3.2. Función de Autocorrelación (ACF)

Autocovarianza normalizada por la varianza $\gamma_0 = \text{Var}(X_t)$:

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\text{Cov}(X_t, X_{t-k})}{\text{Var}(X_t)}, \quad \rho_k \in [-1, 1]. \quad (9)$$

Un $|\rho_k|$ elevado revela una fuerte dependencia lineal a k pasos.

En la ritmicidad cortical, la ACF cuantifica la persistencia oscilatoria: los coeficientes autorregresivos $AR(p)$ derivados de ρ_k (p. ej. `T4_ar_coefficient`) figuraron entre los descriptores seleccionados, reflejando alteraciones en la dinámica temporal de los pacientes.

4. Cambios de Estado y Dinámica No Lineal

Estos descriptores aproximan el contenido frecuencial y la dinámica sin recurrir a una transformada de Fourier explícita.

4.1. Tasa de Cruces por Cero (ZCR)

Cuenta la frecuencia con que la señal centrada cambia de signo:

$$\text{ZCR} = \frac{1}{N-1} \sum_{t=2}^N \mathbb{I}[\text{sign}(X_t) \neq \text{sign}(X_{t-1})], \quad (10)$$

donde $\mathbb{I}[\cdot]$ es la función indicadora. La ZCR es un estimador económico de la frecuencia dominante: para una senoide pura de frecuencia f , se cumple aproximadamente $\text{ZCR} \cdot f_s \approx 2f$.

4.2. Detección de Picos y Valles

Un punto X_t es un *pico* (máximo local) y un *valle* (mínimo local), respectivamente, si:

$$\text{Pico: } X_t > X_{t-1} \wedge X_t > X_{t+1}, \quad (11)$$

$$\text{Valle: } X_t < X_{t-1} \wedge X_t < X_{t+1}. \quad (12)$$

El conteo de picos sobre una vecindad de soporte n (p. ej. `number_peaks_n_5`) aproxima la densidad de eventos oscilatorios y resultó un descriptor relevante en canales temporales.

5. Imperativos de Preprocesamiento

5.1. Filtro de Rango Inter cuartílico (IQR) para Atípicos

Sean Q_1 y Q_3 el primer y tercer cuartil. El rango intercuartílico $\text{IQR} = Q_3 - Q_1$ mide la dispersión del 50 % central de los datos y es *robusto* a valores extremos. La regla de Tukey marca como atípico todo valor fuera del intervalo:

$$[Q_1 - 1.5 \text{IQR}, Q_3 + 1.5 \text{IQR}]. \quad (13)$$

A diferencia del rango o la desviación estándar, el IQR no se contamina por la presencia de los propios atípicos que pretende detectar.

5.2. Discontinuidades y Correlación Espuria

Los vacíos (*gaps*) en el registro o las imputaciones abruptas introducen discontinuidades $|X_t - X_{t-1}|$ anómalas. Estos saltos inflan artificialmente la varianza de la primera diferencia $\Delta X_t = X_t - X_{t-1}$ y distorsionan la autocovarianza γ_k , generando *correlación espuria*: estructura temporal aparente que no proviene de la fisiología sino del artefacto de registro. Por ello, la normalización por canal (*z-score*) y el filtrado de banda preceden obligatoriamente a la extracción de características.

Síntesis: el pipeline transforma $\mathbf{X} \in \mathbb{R}^{1250}$ en un vector $\phi(\mathbf{X})$ de descriptores de los dominios anteriores. Esta representación restaura la tratabilidad estadística (mitiga la dimensionalidad y la dependencia IID) y, de manera crítica, confiere interpretabilidad clínica —cada componente posee un significado físico explícito— condición indispensable para la validación de biomarcadores.